

Reto Babel: atención y Transformers

Traducción secuencia a secuencia, causalidad y ablación posicional

Institución	Universidad del Valle de Guatemala	Curso	Deep Learning y Sistemas In- teligentes
Docente	Kevin Recinos	Integrante A	Pablo Daniel Barillas Moreno · 22193
Modalidad	Grupo de tres	Integrante B	Cindy Mishelle Gualim Pérez · 221226
Fecha	28 de agosto de 2026	Integrante C	Gadiel Ocaña · 231270
Entrega	6 de septiembre de 2026	Elaboración	28 de agosto de 2026

Resultado ejecutivo

El Transformer con codificación posicional alcanzó **98.16% de exactitud por token** y **94.17% de frases completamente correctas** en 240 pares de validación. Al retirar únicamente la posición, ambas métricas cayeron a 77.88% y 54.17%. La diferencia de **20.28 puntos por token** y **40.00 puntos por frase** demuestra, dentro de este idioma controlado, que conocer la ubicación de los tokens es decisivo para reconstruir el orden español.

1,200	240	98,810	22 + 22
frases de entrenamiento	frases de validación	parámetros	épocas comparadas

Investigación guiada I: motivación y arquitectura

1. ¿Qué limitación recurrente buscó resolver el Transformer?

Una RNN calcula h_t a partir de h_{t-1} ; por tanto, el estado siguiente debe esperar al anterior. Vaswani et al. (2017) identifican esta dependencia como una barrera para paralelizar las posiciones de un mismo ejemplo y para aprovechar lotes grandes cuando las secuencias crecen. La ruta entre dos palabras distantes también atraviesa muchos pasos. El Transformer elimina recurrencia y convolución del núcleo y usa atención para relacionar posiciones directamente. Durante entrenamiento, las posiciones conocidas pueden procesarse en paralelo, aunque la inferencia del decoder siga siendo autorregresiva.

La traducción es una prueba exigente porque combina comprensión, alineamiento y generación. No basta reconocer vocabulario: hay que conservar significado y producir otra secuencia con gramática correcta. Reto Babel lo aísla mediante tres reglas: sujeto–objeto–verbo, adjetivo antes del sustantivo y negación después del verbo. El modelo debe aprender la transformación, no copiar el diccionario.

2. Encoder, self-attention causal y atención cruzada

Tres responsabilidades complementarias

1. **Encoder:** contextualiza todos los tokens secretos. Cada posición puede combinar sujeto, objeto, modificadores y verbo mediante self-attention.
2. **Decoder enmascarado:** genera español de izquierda a derecha. Para predecir y_t solo consulta $y_{<t}$; observar el futuro produciría fuga de la respuesta.
3. **Atención encoder–decoder:** las consultas del decoder atienden claves y valores del encoder, permitiendo localizar qué fragmento de la entrada respalda la siguiente palabra española.

La atención escalada se resume como

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V.$$

La máscara causal impone $M_{ij} = 0$ si $j \leq i$ y $M_{ij} = -\infty$ si $j > i$. ‘nn.Transformer’ encapsula la atención multi-cabeza; el laboratorio aporta embeddings, posición, padding y máscaras con dimensiones correctas. Esto respeta el alcance: comprender y conectar la arquitectura oficial, no reimplementarla.

Flujo completo de una traducción

1. Entrada	IDs secretos $\rightarrow$ embedding $\rightarrow$ posición	2. Encoder	Produce una memoria contextual por token
3. Decoder	Consume español previo con máscara causal	4. Atención cruzada	Consulta la memoria y alinea contenido
5. Salida	Proyección lineal a $ V_{tgt} $ logits	6. Decisión	‘argmax’ agrega una palabra y repite

Teacher forcing frente a inferencia

Durante entrenamiento se conoce la oración objetivo y el decoder recibe el prefijo correcto desplazado; esto permite calcular simultáneamente la pérdida de todas las posiciones sin violar causalidad. Durante traducción no existe ese objetivo: la secuencia comienza con ‘<SOS>’ y cada predicción se convierte en entrada del paso siguiente. Esta diferencia explica por qué una pérdida baja no garantiza automáticamente una frase perfecta: un error temprano puede propagarse durante la generación greedy.

Síntesis

El Transformer surgió para reducir el cómputo secuencial y acortar las rutas entre dependencias. En Babel, la ventaja central no es construir un modelo enorme, sino separar de forma verificable representación de entrada, causalidad de salida y alineamiento entre idiomas.

Investigación guiada II: posición, ventajas y costos

3. ¿Por qué necesita posición?

La atención relaciona contenidos, pero sin recurrencia ni convolución no posee una noción inherente del índice. Un conjunto de embeddings permutado conserva los mismos elementos; para distinguir “antes”, “después” y “al final” debe inyectarse posición. El artículo suma señales sinusoidales de dimensión d_{modelo} :

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{modelo}}}}\right), \quad PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{modelo}}}}\right).$$

Estas ondas diferencian posiciones y permiten representar desplazamientos relativos. La predicción previa fue que eliminar posición reduciría especialmente frases exactas: el modelo podría memorizar correspondencias léxicas, pero confundiría quién realiza la acción y quién la recibe. La caída observada de 40.00 puntos porcentuales confirma esa predicción.

4. Ventaja y costo frente a recurrencia

Capa	Complejidad por capa	Operaciones secuenciales	Ruta máxima
Self-attention	$\mathcal{O}(n^2 d)$	$\mathcal{O}(1)$	$\mathcal{O}(1)$
Recurrente	$\mathcal{O}(nd^2)$	$\mathcal{O}(n)$	$\mathcal{O}(n)$

La atención permite procesar posiciones en paralelo y relacionar dos tokens en una sola capa. Su costo es construir relaciones por pares: memoria y cómputo crecen cuadráticamente con el largo. En Babel las frases son cortas, así que ese costo es pequeño; también lo es parte de la ventaja de paralelización. El beneficio experimental es más claro: la arquitectura modela relaciones globales y la ablación permite demostrar que las usa junto con posición.

Relación con la implementación

- Los embeddings se multiplican por $\sqrt{d_{\text{modelo}}}$ antes de sumar posición.
- ‘batch_first=True’ conserva tensores (B, L, d) y simplifica la integración con el ‘DataLoader’.
- La máscara de padding excluye ‘<PAD>’; la causal excluye palabras futuras. No son intercambiables.
- Cuatro cabezas permiten atender subespacios distintos sin exceder el límite competitivo: el modelo total tiene 98,810 parámetros.

Qué elimina exactamente la ablación

Componente	Con posición	Sin posición
Contenido léxico	Embeddings aprendidos	Los mismos embeddings
Orden explícito	Senos y cosenos sumados	Ninguna coordenada añadida
Capacidad	98,810 parámetros	98,810 parámetros
Datos y optimización	Semilla 42, Adam, 22 épocas	Exactamente iguales

La comparación no pregunta si un Transformer sin posición puede memorizar algo; pregunta si puede asignar roles de forma estable cuando aparecen los mismos tipos de entidades en posiciones intercambiables. El 77.88% por token sin posición confirma que conserva diccionario y patrones frecuentes. La caída a 54.17% de frases exactas localiza la debilidad en la estructura completa.

Costo cuadrático en el contexto del reto

Si una frase duplica su largo de n a $2n$, las comparaciones de atención pasan aproximadamente de n^2 a $4n^2$. En los largos pequeños de Babel esto cabe holgadamente en memoria y el modelo completo permanece por debajo de cien mil parámetros. La misma decisión no se trasladaría sin análisis a documentos extensos: allí podrían requerirse atención local, ventanas o arquitecturas eficientes.

Resultado conceptual

La posición no es una decoración del embedding. En una tarea cuya dificultad consiste precisamente en reorganizar tokens, funciona como la coordenada que permite transformar una colección de palabras en una secuencia gramatical.

Datos, preparación y protocolo experimental

Datos asignados

Recurso	Cantidad
Diccionario	22 tokens
Entrenamiento	1,200 frases
Validación	240 frases
Vocabulario secreto	26
Vocabulario español	26
Validación con negación	115 frases

Unidad de aprendizaje

Cada fila contiene 'idioma_secreto' y 'espanol'. Se tokeniza por espacios y se agregan '<SOS>' y '<EOS>'. Los vocabularios incorporan '<PAD>' y '<UNK>'; ambos tienen 26 símbolos incluidos los especiales. No se usa NumPy, modelos preentrenados ni servicios externos.

Lotes y máscaras

'pad_sequence(..., batch_first=True)' completa cada lote hasta su largo máximo. La máscara de padding vale 'True' donde aparece '<PAD>'. La máscara causal es triangular superior y evita que el decoder consulte posiciones futuras. Las verificaciones oficiales comprobaron forma, tipo booleano, diagonal visible y futuro oculto.

Modelo y teacher forcing

d_{modelo}	48	Cabezas	4
Capas encoder/decoder	2/2	Dimensión feed-forward	96
Dropout	0.1	Optimizador	Adam, 2×10^{-3}
Épocas	22	Parámetros	98,810
Batch train/val	64/128	Semilla	42

Con teacher forcing, la entrada del decoder es $y_{0:T-1}$ y el objetivo $y_{1:T}$. La pérdida ignora padding:

$$\mathcal{L} = -\frac{1}{N} \sum_{t: y_t \neq PAD} \log p_{\theta}(y_t \mid y_{<t}, x).$$

Se limpian gradientes solo al entrenar, se aplica 'clip_grad_norm_' con norma 1 y se conserva el estado con menor pérdida de validación. La pérdida se pondera por tokens reales para evitar que el padding altere el promedio.

Diseño de la ablación

El modelo sin posición conserva datos, orden, semilla, arquitectura, optimizador y 22 épocas. Solo cambia **usar_posicion=False**. Esta intervención aislada permite atribuir diferencias a la información posicional, dentro de la variabilidad controlada por la semilla.

Ejemplos observados y reglas que debe inducir

Idioma secreto	Español	Evidencia gramatical
moro somi moro disa mapa zita	la niña encuentra la médica azul	Verbo final pasa al centro; adjetivo se pospone
fefo gero fefo ragi zizi nava	el niño lee el jardinero joven	Conserva dos sintagmas y reasigna el adjetivo
moro mapa fefo sena rino zita riga	la médica no encuentra el perro verde	Negación posterior al verbo pasa antes del verbo

Estos pares muestran por qué el diccionario es insuficiente: contiene significados aislados, pero no identifica por sí mismo cuál entidad actúa, dónde se coloca el verbo ni cómo se mueve la negación. La supervisión paralela entrega la evidencia para aprender esas transformaciones.

Hallazgos del análisis exploratorio

Indicador	Train	Validación	Interpretación
Frases únicas	1,200	240	No hay duplicados internos
Traslape entre particiones	0 frases		Validación no repite entrenamiento
Tokens fuera de vocabulario	—	0	La dificultad no proviene de OOV
Largos observados	5–7	5–7	Dominio corto y controlado
Negación	591 (49.25%)	115 (47.92%)	Distribución estable
Mismo determinante	521 (43.42%)	116 (48.33%)	Subgrupo estructural más ambiguo

El EDA descarta fuga por repetición y revela vocabulario completamente cubierto. La dificultad principal es composicional: casi la mitad de validación presenta sujeto y objeto con el mismo artículo, precisamente el patrón que domina los errores de inversión observados.

Integridad

El notebook se ejecutó de arriba abajo: 36 celdas, 19 de código, cero errores y cinco verificaciones 'OK'. Las celdas oficiales con 'assert' se conservaron literalmente.

Entrenamiento y resultados cuantitativos

98.16%

exactitud token, con posición

94.17%

frases exactas, con posición

77.88%

exactitud token, sin posición

54.17%

frases exactas, sin posición




Figure 1: Pérdida de entrenamiento y validación bajo las dos configuraciones.

Configuración	Mejor pérdida val.	Exactitud token	Frases exactas
Con posición	0.0406	98.16%	94.17%
Sin posición	0.1044	77.88%	54.17%
Δ con – sin	-0.0637	+20.28 pp	+40.00 pp

El modelo posicional supera el umbral oficial de 70% por token con margen de 28.16 puntos. Su 94.17% de frases exactas implica 226 oraciones completamente correctas de 240 y 14 fallos. El modelo sin posición conserva 77.88% por token, por encima del mínimo funcional, pero solo 130 oraciones exactas. Esto demuestra por qué la métrica de frase completa es más exigente: errores pequeños de orden invalidan toda la traducción.

La menor pérdida posicional aparece al final, mientras el modelo sin posición alcanza su mínimo antes y termina ligeramente peor; esa estabilización sugiere un límite de representación, no simplemente falta de épocas. Aumentar entrenamiento no sustituye la coordenada ausente.

Qué mide cada resultado

La exactitud por token compara palabras en la misma posición y concede crédito parcial; formalmente es $\sum_i \mathbb{I}(\hat{y}_i = y_i) / N$. La exactitud de frase exige $\mathbb{I}(\hat{\mathbf{y}} = \mathbf{y})$ y penaliza cualquier inserción, omisión, sustitución o intercambio. Por eso 98.16% por token se traduce en 94.17% de frases: los errores son escasos, pero afectan la condición estricta. En contraste, el 77.88% sin posición todavía reconoce gran parte del léxico, mientras 54.17% de frases muestra que esa señal parcial no basta para ordenar consistentemente.

Resultado sobre 240 frases	Con posición	Sin posición
Frases completamente correctas	226	130
Frases con al menos un error	14	110
Parámetros entrenables	98,810	98,810

Decisión

Se selecciona el Transformer con posición para las traducciones finales. Gana en pérdida, exactitud parcial y exactitud estricta con exactamente el mismo número de parámetros; por tanto, la mejora no proviene de mayor capacidad.

Ablación, negación y análisis de errores




Figure 2: Efecto de retirar la codificación posicional.

Sensibilidad a negación

Subgrupo	Token	Frase
Con negación ($n = 115$)	97.71%	92.17%
Sin negación ($n = 125$)	98.63%	96.00%

Lectura

La negación reduce 0.92 puntos la exactitud por token y 3.83 puntos las frases exactas. El modelo aprende a mover “no” desde después del verbo secreto hasta antes del verbo español, pero la estructura más larga aumenta oportunidades de error. Aun así, 92.17% de frases negativas es evidencia fuerte de la regla aprendida.

Patrón de error concreto

Secreto	Esperado	Predicción
fefo rino fefo sena gero pefe riga	el perro no lleva el niño verde	el niño no lleva el perro verde
moro seza moro povo mapa nava riga	la maestra no lee la médica grande	la médica no lee la maestra grande
fefo rino fefo sena gero zita riga	el perro no encuentra el niño verde	el niño no encuentra el perro verde
fefo mefi fefo disa gero rizo	el músico cuida el niño azul	el niño cuida el músico azul

En los diez errores representativos exportados domina la inversión sujeto–objeto: se conservan determinantes, verbo, negación y adjetivo, pero se intercambian las dos entidades. Esto es coherente con la dificultad central del idioma: dos sintagmas nominales similares deben asignarse a roles distintos a partir de su posición. No es un fallo de diccionario; es un fallo estructural residual.

Qué se intentaría después

- Examinar atención o gradientes por posición para confirmar qué tokens controlan los roles.
- Aumentar ejemplos con pares de entidades intercambiadas, sin cambiar la gramática ni filtrar validación.
- Comparar greedy con beam search solo como ablación de inferencia; no usar traductores externos.
- Evaluar frases más largas y combinaciones léxicas no vistas para medir generalización composicional.

Veredicto de posición

La posición aporta una mejora material y consistente: +20.28 pp por token y +40.00 pp en frases completas. La magnitud, con una intervención única y capacidad idéntica, respalda causalmente la predicción formulada antes del entrenamiento.

Conclusiones, límites y reproducibilidad

Conclusiones principales

1. La conexión correcta de embeddings, máscaras y ‘nn.Transformer’ produce un traductor compacto de 98,810 parámetros que alcanza 98.16% por token y 94.17% de frases exactas.
2. La máscara causal es indispensable para una pérdida válida: impide que el decoder vea la respuesta futura. La máscara de padding evita que el relleno se convierta en contenido.
3. La ablación confirma la hipótesis posicional. Sin posición, el modelo retiene vocabulario y patrones frecuentes, pero pierde 40 puntos en oraciones completas.
4. La negación se aprende con 92.17% de frases exactas. El error residual dominante es intercambiar sujeto y objeto, no omitir el verbo ni traducir mal las palabras.
5. Para el concurso debe conservarse el modelo posicional. La prueba oculta determinará si el rendimiento se sostiene en combinaciones nuevas del mismo idioma.

Alcance y limitaciones

Los 240 ejemplos de validación provienen del mismo vocabulario y mecanismo gramatical que entrenamiento. La alta exactitud demuestra aprendizaje dentro de este dominio, no traducción abierta. No se evaluaron palabras desconocidas, otra gramática, frases mucho más largas, ruido ni distribución diferente. La decodificación greedy puede descartar una secuencia globalmente mejor. Además, una sola semilla no cuantifica variación estadística; se mantiene porque la rúbrica exige una comparación exactamente controlada.

Evidencia que podría cambiar la conclusión

La recomendación posicional se revisaría si varias semillas mostraran una diferencia cercana a cero, si en frases más largas la ventaja desapareciera o si una prueba oculta revelara que el modelo memorizó plantillas sin generalizar combinaciones. La evidencia más fuerte sería un conjunto nuevo construido con el mismo diccionario y reglas, pero con pares de sujeto y objeto no observados juntos. También sería útil repetir la ablación con longitudes estratificadas para comprobar si la brecha aumenta cuando hay más decisiones de orden.

Contribuciones del grupo

Pablo Daniel Barillas Moreno (22193), Integrante A, trabajó en lectura sobre atención, investigación guiada, lotes, padding y máscaras. **Cindy Mishelle Gualim Pérez (221226), Integrante B**, trabajó en configuración del Transformer, teacher forcing, entrenamiento y reproducibilidad. **Gadiel Ocaña (231270), Integrante C**, trabajó en decodificación progresiva, evaluación, experimento posicional y análisis de errores. Los tres integrantes revisaron las salidas y deben poder explicar todos los bloques. La asistencia computacional apoyó estructura, depuración y presentación; las fuentes académicas son el artículo original y PyTorch.

Reproducción y entrega

Secuencia de verificación

1. Mantener ‘diccionario.csv’, ‘entrenamiento.csv’ y ‘validacion.csv’ dentro de ‘CARPETA_DATOS/’.
2. Abrir ‘S09_Lab05_Reto_Babel_ESTUDIANTE.ipynb’, reiniciar kernel y ejecutar todo.
3. Confirmar cinco mensajes ‘OK’, ausencia de errores y salidas visibles.
4. Pegar únicamente las frases secretas oficiales en ‘frases_del_reto’; las traducciones deben proceder del modelo.
5. Entregar exclusivamente el notebook con el nombre solicitado por el PDF. El informe es evidencia complementaria.

Referencias APA 7

PyTorch. (2026). *Transformer—PyTorch documentation*. <https://docs.pytorch.org/docs/stable/generated/torch.nn.Transformer.html>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30. <https://arxiv.org/abs/1706.03762>

Cierre

El resultado es coherente con la teoría y con las salidas observadas: cuando la tarea depende de reordenar, la atención necesita una referencia explícita de posición. El modelo no solo supera el mínimo funcional; la ablación demuestra por qué lo logra.